

Automatisierte Emotionserkennung

Entwicklung und Optimierung einer CNN-basierten Inferenz-Applikation

Thomas Anschütz

Matrikelnummer: IU14142014

Studiengang: Angewandte künstliche Intelligenz

IU Internationale Hochschule

Modul: Projekt Computer Vision

Tutor: Ahmet Nasri

17. September 2026

Herausforderung

- Mimik ist ein zentraler Kanal menschlicher Kommunikation, aber schwer automatisiert auswertbar.
- Herausforderungen bei Reallabor-Daten:
 - Subtile Mikroexpressionen
 - Schwankende Belichtung & Blickwinkel
 - Starke Klassenungleichgewichte

Projektziel

- Entwicklung eines performanten Deep-Learning-Modells zur Erkennung von sieben Emotionsklassen.
- Bereitstellung einer interaktiven Web-Anwendung.


Struktur & Parameter

- **Umfang:** 35.887 Grauwertbilder (48×48 Pixel).
- **Klassen (7):** *Anger, Disgust, Fear, Happy, Sad, Surprise, Neutral*.
- **Zielformat:** Repräsentative Verteilung für Ekman's Basisemotionen.

Herausforderungen & Datenqualität

- **Class Imbalance:** Starkes Ungleichgewicht (z. B. *Disgust*: 547 vs. *Happy*: 8989 Bilder).

Systemarchitektur (End-to-End)



Kernanforderung an die Architektur

Klare Entkopplung von Gesichtsdetektion (Frontend) und Modellinferenz (Backend) für hohe Ausfallsicherheit und Wartbarkeit.

Iterative Modellentwicklung & Baselines

Iterativ-Stufe	Architektur	Top Val-Acc	Beobachtung / Erkenntnis
Baseline	Custom CNN (flach)	49,3 %	Kapazitätsgrenze schnell erreicht.
Transfer Learning	MobileNetV2	59,3 %	Leichtbau-Modell, leichtes Overfitting.
Transfer Learning	ResNet50 (ohne Augm.)	62,7 %	Hohe Accuracy, aber starker Loss-Anstieg.
Data Augmentation	ResNet50 (mit Augm.)	62,6 %	Stabilste Konvergenz.

Erkenntnis

Data Augmentation verringert Overfitting bei ResNet50 drastisch und sorgt für konsistente Leistung auf unbekannten Validierungsdaten.

Transformation & Augmentation

- **Resizing:** Upscaling von 48×48 auf 224×224 (RGB) für ResNet50-Konformität.
- **Augmentierung:** Zufällige Rotation, Zoom und horizontale Spiegelung zur Overfitting-Vermeidung.

In-Model GPU Preprocessing

CPU-Bottleneck vermieden

Preprocessing-Schichten sind direkt in die Keras-Modellarchitektur integriert.

- Speicherschonender Datentransfer.
- Maximale GPU-Auslastung (NVIDIA P100) während des Trainings.

Zweistufiges Fine-Tuning

- ➊ **Stufe 1:** Einfrieren des Feature-Extraktors, Training des Dense-Heads.
- ➋ **Stufe 2:** Blockweises Auftauen (*Unfreezing*) oberer ResNet-Schichten.



Unfreezing-Ergebnisse:

- *conv_5*: Stagnation bei 41,2 %.
- *conv_4–5*: Erholung auf 52,8 %.
- *conv_3–5*: 61,5 % (Inkongruenz vermieden).

Class Weights & Sättigung

- **Class Weights Evaluierung:** 62,2 % Val-Acc (keine Steigerung gegenüber ungewichteter Loss).
- **Sättigungsgrenze:** Alle fortgeschrittenen Ansätze pendelten sich zwischen 61 % und 63 % ein.
- **Fazit:** Methodische Datensatz-Sättigung erreicht → Fokus auf Inferenz & Deployment verlagert.


Modell-Evaluierung: Lernkurven & Konvergenz



Erkenntnisse zum Trainingsverlauf


- **ResNet50 mit Augmentation:** Erreicht das stabilste Konvergenzverhalten mit minimaler Lücke zwischen Train- und Val-Loss.
- **Vermeidung von Overfitting:** In-Model Data Augmentation stabilisiert den Validation Loss im Vergleich zum nicht-augmentierten ResNet50 spürbar.
- **Baseline:** Das flache Custom-CNN verbleibt mit 49,3 % deutlich unter der Kapazität der Transfer-Learning-Modelle.

Fehlermuster-Analyse: Konfusionsmatrix



Analyse der Klassen-Erkennungsraten

- **Stärke bei klaren Merkmalen:** *Happy* ($F1 = 0,74$) und *Neutral* ($F1 = 0,85$) werden dank prägnanter Mund- und Augenpartien sehr zuverlässig klassifiziert.
- **Überlappung negativer Affekte:** Visuell ähnliche Emotionen (z. B. *Fear* vs. *Sad*) weisen hohe Verwechslungsraten auf.
- **Datensatz-Limitation:** Das 48×48 -Raster erschwert die Differenzierung subtiler Stirn- und Augenbrauenbewegungen bei *Fear* ($Recall = 0,23$).



Benutzeroberfläche & Inferenz

- **Interaktiver Upload:** Bildanalyse via Drag-&-Drop oder Dateiauswahl.
- **Gesichtslokalisierung:** Automatische Detektion des Gesichtsfeld-Ausschnitts vor der Modellinferenz.
- **Echtzeit-Inferenz:** Vorhersage der Wahrscheinlichkeiten für alle 7 Emotionsklassen.
- **Visuelles Feedback:** Hervorhebung der dominanten Emotion inklusive Zuverlässigkeitswert.

Wechsel von OpenCV zu MTCNN

- **Problem mit OpenCV:** Native C++ Systemabhängigkeiten (z. B. *libGL.so*) verursachten Kompatibilitätsprobleme in der Container-Umgebung.
- **Lösung MTCNN:** Reine Python/*pip*-Abhängigkeit sowie höhere Robustheit bei verdeckten und geneigten Gesichtern.

Containerisierte Entwicklung

- **Isolierte Laufzeitumgebung:** Nutzung eines vorgefertigten Python-Containers zur Entwicklung.
- **Reproduzierbarkeit:** Vollständige Entkopplung vom Host-Betriebssystem und dessen Bibliotheken.
- **Vereinfachtes Setup:** Deterministische Steuerung aller Bibliotheksversionen für Inferenz und Streamlit.

Kern-Ergebnisse

- Transfer Learning mit ResNet50 steigert die Erkennungsrate von 49,3 % (Baseline) auf 62,6 %.
- In-Model Preprocessing behebt CPU-Flaschenhälse auf Cloud-GPUs vollständig.
- MTCNN und Docker ermöglichen ein leichtgewichtiges, plattformunabhängiges Deployment.

Ausblick & Erweiterungen

- **Datenqualität:** Training auf hochauflösenden Datensätzen (z. B. AffectNet) zur Überwindung der FER-2013 Sättigung.
- **Video-Inferenz:** Erweiterung des Streamlit-Frontends um Echtzeit-Webcam-Streaming.